

课程实验报告

信息检索实验报告

基于 TF-IDF 与 BM25 的技能检索系统

组号：第15组

成员一：张明辉-2023211959

成员二：杨佳怡-2023212446

日期：2026 年 6 月 3 日

摘要

这次实验围绕 skills.sh 上的 1000 条 AI 技能描述做了一个离线检索系统。数据先由 paqu.py 抓下来，再把标题、描述、仓库信息和外置 SKILL.md 统一规整到同一份数据集里。检索部分没有走重模型路线，而是把 TF-IDF 余弦相似度、BM25 和一组后置 boost 规则叠在一起，目标很直接：查询里既有英文短词，也有中文任务描述，结果还得能解释为什么排成这样。

按当前仓库里的真实运行结果，索引覆盖 1000 篇文档、15543 个 term，索引文件大小约 9.10MB。对 core_relevance.json 中 42 条查询做评测时，纯 TF-IDF 的 MRR@5 最好，为 0.9107；混合检索的 P@5 和 nDCG@5 稍高，分别达到 0.2810 和 0.8988。固定权重扫描也说明 BM25 更像补分项，权重压在 0.02 到 0.05 一段时效果最稳。

1 引言

当前，各类 AI Agent 层出不穷，与之适配的 Skills 生态也日益活跃。一个出色的 Skill 能让 AI 在完成任务时事半功倍：当用户提出相关问题时，AI 可自动检索并加载对应 Skill 的内容，再结合提示词生成精准的回答。这正是 Skills 检索系统的核心价值所在——通过高效检索与智能匹配，当用户想要搜索一个自己可能用到的 skills 时可以在这个里面查找到一个自己可以直接使用的 skills 或者可以从这个检索系统当中找到一些可以自己创建自己的 skills 的灵感。

面对这个需求，我们提出了这个 skills 检索系统，当用户想要找到一个相关的 skills 时，可以尽量快地从技能库里找出合适的 skill。难点不在规模，而在文本形态很杂。查询既可能是 API design 这种英文短语，也可能是“前端页面设计”“向量搜索 Qdrant”这种中文或中英混合表达。只靠标题精确匹配会漏召回，只靠模糊匹配又容易把一堆相关但不对题的 skill 推上来。

数据来自 skills.sh 的 1000 条 skill 记录，主文件是 data/skills_data.json。每条记录至少包含 skill_name、owner、repo、description、category、detail_url、repo_url、first_seen、weekly_installs_num、github_stars_num 等字段；较长的 SKILL.md 文本被外置到 data/skill_md/ 目录，主数据里只保留路径。当前快照里一共有 917 条记录带外置 SKILL.md，203 条记录缺 description，所以检索不能只盯着一个字段看。

总体上看，本次实验需要完成三件事：第一，跑通爬虫→清洗→索引的全链路，搞清楚每个环节输入是什么、输出是什么、中间丢了什么信息、哪些字段是空的，哪些字段爬取过程中出现问题等，方便作为后续检索和抽取的基准；第二，TF-IDF 和 BM25 不能只跑一遍看分数就过。实验要回答：两种算法的排序差异在哪？融合权重从 0 到 1 变化时检索结果怎么变？boost 规则对哪些 query 管用、对哪些是负优化？第三，做消融实验：关掉 BM25 只留 TF-IDF、关掉 boost、换不同的融合权重——看每个组件到底贡献了多少。分清楚哪些设计经得起数据检验，哪些只是理论上说得通但对实际检索质量没影响。

2 数据获取与预处理

2.1 爬虫与落盘流程

paqu.py 做的是一条偏工程化的抓取链路。首页靠滚动收集详情页 URL，详情页再用 curl/urllib 拉 HTML，之后从 SSR 文本和 `_next.f.push` 片段里拆出字段。如果页面里有 Show more，脚本会退到 Selenium，把完整 SKILL.md 展开后再提取。抓取过程中所有中间结果都会写进 checkpoint，失败 URL 也会单独记录，后面可以重试。整个流程见图 1。




图 1: 数据抓取与落盘流程

2.2 数据字段与完整性

表 1 列了检索阶段最常用的字段以及这些字段成功在网页成功爬取到内容的 skills 条数。这里并没有把所有原始键都摊开，只保留对排序和结果解释最有用的部分。

表 1: 检索系统使用的主要字段与当前数据完整性统计

字段名	含义	非空条数
skill_name	技能名，标题 boost 的核心字段	1000
description	简介文本，检索主语料之一	797
category	规则推断或原始类别，用于轻量补分	1000
repo_url	GitHub 仓库链接，辅助说明结果来源	1000
wkly_isls_num	周安装量，参与热度修正	992
git_stars_num	GitHub star 数，参与热度修正	984
skill_path	外置 SKILL.md 纯文本路径	917
skill_raw_path	外置原始文本路径	917

这批数据有两个特点。第一，文本主体几乎全是英文，标题和描述同时含 CJK 的记录只有 5 条，说明“中英混合”更多出现在查询侧，不是文档侧。第二，SKILL.md 的补齐价值很高。主数据只有 797 条带 description，但有 917 条能读到外置技能文档，后面做检索时如果只用标题和简介，很多长文档里的关键术语根本进不了索引。

2.3 文本预处理

IR 子系统的预处理在 `ir_system/src/skills_ir/text.py`。它没有接第三方分词器，而是自己做了一套轻量规则：

- 英文 token 用正则抓取后，再生成若干变体，例如把连字符和下划线拆开，把复数还原成词干。
- 中文片段同时保留整段、单字和双字切片，用来弥补没有中文分词器时的召回损失。
- 文档建模时按字段权重累计词频，标题权重 4.0，描述权重 3.0，类别权重 2.5，仓库 owner / repo 各 1.2。
- 查询阶段还会查配置里的扩展词典，例如“前端”会扩成 `frontend/ui/ux/react/vue/css`，“向量数据库”会扩成 `vector/database/qdrant/embedding/retrieval`。

这种做法不精致，但对当前数据集足够实用。它的优点是可控、可解释、重建成本低；缺点也很明显，中文 token 会被切得比较碎，所以后面混合检索里我会专门把中文查询的 BM25 权重压低。

3 核心算法

3.1 TF-IDF 与余弦相似度

文档先被映射到带字段权重的词频向量。设 $tf_{t,d}$ 表示 term t 在文档 d 里的加权词频， N 为文档总数， df_t 为 term 的文档频次，那么代码里采用的逆文档频率是

$$\text{idf}(t) = \log \frac{N+1}{df_t+1} + 1. \quad (1)$$

文档向量中的 term 权重写成

$$w_{t,d} = (1 + \log tf_{t,d}) \cdot \text{idf}(t). \quad (2)$$

查询向量沿用同一套权重定义，最后的余弦相似度为

$$s_{\cos}(d, q) = \frac{\sum_{t \in q \cap d} w_{t,q} w_{t,d}}{\|q\|_2 \|d\|_2}. \quad (3)$$

这里选对数词频而不是原始词频，主要是想压一压长 SKILL.md 里高频重复术语的影响。当前数据里长文档不少，直接堆原始词频会把“模板化重复描述”推得太高。

3.2 BM25

BM25 部分采用 Robertson 和 Zaragoza 总结过的标准写法。对查询 q 和文档 d ，得分为

$$s_{\text{bm25}}(d, q) = \sum_{t \in q} \text{idf}_{\text{bm25}}(t) \cdot \frac{tf_{t,d}(k_1 + 1)}{tf_{t,d} + k_1 \left(1 - b + b \frac{|d|}{\text{avgdl}}\right)}, \quad (4)$$

其中

$$\text{idf}_{\text{bm25}}(t) = \log \left(\frac{N - df_t + 0.5}{df_t + 0.5} + 1 \right). \quad (5)$$

项目里固定 $k_1 = 1.5$ 、 $b = 0.75$ 。这个选择比较保守： k_1 留出一定词频增益，但不会把重复堆词推得太夸张； $b = 0.75$ 则保留了常见的长度归一化强度。因为文档平均长度已经达到 331.83 个 token，长度归一化如果太弱，长 SKILL.md 会吃掉不少短 skill 的位置。

3.3 混合融合与动态权重

BM25 原始分数和余弦分数不在同一量纲上，代码先做最大值归一化：

$$\tilde{s}_{\text{bm25}}(d, q) = \frac{s_{\text{bm25}}(d, q)}{\max_{d'} s_{\text{bm25}}(d', q)}. \quad (6)$$

然后按式 (7) 融合：

$$s_{\text{hyb}}(d, q) = (1 - \alpha_q) s_{\text{cos}}(d, q) + \alpha_q \tilde{s}_{\text{bm25}}(d, q). \quad (7)$$

这里最关键的是 α_q 不是固定常数，而是按查询形态动态设定：

$$\alpha_q = \begin{cases} 0.02, & q \text{ 含 CJK 字符,} \\ 0.08, & q \text{ 不含 CJK 且有效 token 数} \leq 2, \\ 0.10, & 3 \leq \text{token 数} \leq 4, \\ 0.12, & 5 \leq \text{token 数} \leq 8, \\ 0.14, & \text{token 数} > 8. \end{cases} \quad (8)$$

这样设计的原因很直接。当前文档侧几乎全英文，中文查询主要靠扩展词典把语义桥接到英文术语上。如果这时把 BM25 权重给高了，细碎的中文 token 反而容易制造噪声；英文短查询则更适合让 BM25 补一点“词面直击”的分。

3.4 后置 boost 规则

只靠式 (7) 还不够。很多用户更在乎“标题是不是直接对上了”“这个 skill 是不是很热”，这些东西单纯的向量分数感知得不强，所以代码又做了一层加法 boost：

$$s(d, q) = s_{\text{hyb}}(d, q) + \Delta_{\text{title}} + \Delta_{\text{desc}} + \Delta_{\text{category}} + \Delta_{\text{coverage}} + \Delta_{\text{phrase}} + \Delta_{\text{pop}}. \quad (9)$$

各项的具体含义如下。

- 查询完整串落在标题中时，+0.25；落在描述中时，+0.12。
- 查询 token 命中 category 时，+0.05。
- 对短查询或中文查询，如果某个 token 与标题完全相同，再额外 +0.22。
- 标题命中的 token 每个加 0.12，上限 0.36；description 追加命中的 token 每个加 0.02，上限 0.12。
- token 覆盖率按比例折算，最高再给 0.30。
- 配置文件里还写了若干领域短语规则，例如 Qdrant、PDF、video translation 等。
- 热度修正采用

$$\Delta_{\text{pop}} = 0.006 \log(1 + \text{installs}) + 0.005 \log(1 + \text{stars}). \quad (10)$$

这个地方boost 不是拿来替代主排序的，而是补统计模型不擅长表达的那一点偏好。真正决定底盘的还是 TF-IDF 和 BM25；热度项最多只是把两个相关度接近的结果再拉开一点。

3.5 倒排索引结构

索引最终会写到 `ir_system/runtime/skills_ir_index.json`。表 2 给出了主要字段和当前规模。

表 2: IR 倒排索引的核心字段与当前规模

字段	含义	当前规模
<code>documents</code>	原始文档数组，保留排序后回填所需字段	1000
<code>postings</code>	TF-IDF 倒排表: <code>term</code> $\rightarrow$ <code>{doc: weight}</code>	15543 个 term
<code>idf</code>	余弦空间的 IDF 表	15543
<code>doc_norms</code>	文档向量二范数	1000
<code>bm25_idf</code>	BM25 的 IDF 表	15543
<code>bm25_tf</code>	BM25 词频表: <code>term</code> $\rightarrow$ <code>{doc: tf}</code>	84696 个 posting 对
<code>doc_lengths</code>	文档长度表	1000
<code>avg_doc_length</code>	语料平均长度	331.83

索引文件总大小约 9.10 MB，84696 个 posting 对平均下来每个 term 连接 5.45 篇文档，说明词表还是挺稀疏的。对这种规模的数据，JSON 落盘虽然不算最省空间，但调试时直接能看，性价比很高。

3.6 检索流程伪代码

算法 1 把实际搜索流程压缩成了几个关键步骤。代码里还有结果去重、snippet 生成等细节，这里先不展开。

算法 1: 混合检索主流程

输入: 查询 q , 返回条数 k
输出: 排序后的结果列表 R

- 1 $T \leftarrow \text{TOKENIZE}(q)$
- 2 $T' \leftarrow \text{EXPANDQUERY}(T)$
- 3 **if** T' 为空 **then**
- 4 **return** $[]$
- 5 $Q \leftarrow \text{BUILDQUERYWEIGHTS}(T')$ using Eq. (2)
- 6 $S_{\text{cos}} \leftarrow \text{SPARSECOSINEACCUMULATE}(Q, \text{postings})$
- 7 $S_{\text{bm25}} \leftarrow \text{BM25SCORE}(T', \text{bm25_tf}, \text{doc_lengths})$
- 8 $\alpha_q \leftarrow \text{CHOOSEALPHA}(q, T')$ using Eq. (8)
- 9 **foreach** 候选文档 d **do**
- 10 $\tilde{s}_{\text{bm25}}(d, q) \leftarrow S_{\text{bm25}}(d, q) / \max S_{\text{bm25}}$
- 11 $s_{\text{hyb}}(d, q) \leftarrow (1 - \alpha_q)S_{\text{cos}}(d, q) + \alpha_q\tilde{s}_{\text{bm25}}(d, q)$
- 12 $s(d, q) \leftarrow \text{APPLYBOOSTS}(d, q, s_{\text{hyb}})$
- 13 按 $s(d, q)$ 降序排序
- 14 按标准化标题去重, 保留每个 skill name 的最高分结果
- 15 **return** top- k 结果

4 实验设计与过程

4.1 实验环境

操作系统	Windows 10
Python	3.11.5
包管理	conda
关键依赖	scikit-learn (TF-IDF)、numpy、Flask (Web 界面)
GLiNER 模型	urchade/gliner_multi-v2.1 (mdeberta-v3-base 骨干)
硬件	CPU-only, 无 GPU

4.2 评测集与指标

主评测集使用 `ir_system/eval/core_relevance.json`, 共 42 条查询, 其中英文 24 条、中文 6 条、mixed 12 条。CLI 代码里原生实现了 Hit@K、Top1 Accuracy、MRR@K、Recall@K、Precision@K; 为了把排序位置区分得更细, 我额外补算了 nDCG@5。这里的折

扣累计增益采用二值相关性：

$$\text{nDCG}@k = \frac{\sum_{i=1}^k \frac{rel_i}{\log_2(i+1)}}{\sum_{i=1}^{\min(k, |G|)} \frac{1}{\log_2(i+1)}}, \quad (11)$$

其中 G 为当前查询的相关 skill 集合。

除了主评测集，还有 `multilingual.json` 用来观察中文和 `mixed` 查询在不同模式下的差别。它不是主表的来源，但对解释动态 α 很有帮助。

4.3 运行命令

实验中使用四个核心命令完成索引构建、评测、模式对比与交互检索。下面逐一说明每个命令的输入、输出和在实验链路中的位置。

4.3.1 build-index

```
python ir_system/skills_ir_system.py build-index
```

这是所有检索操作的前置步骤：把 `data/skills_data.json` 中 1000 条 skill 记录的标题、描述、类别和外置 `SKILL.md` 文本全部过一遍，完成分词和加权后写入倒排索引文件 `ir_system/runtime/skills_ir_index.json`。索引内含 TF-IDF 倒排表 (`postings`)、BM25 词频表 (`bm25_tf`)、两种 IDF 表、文档长度与向量范数表，共 15543 个 term、84696 个 posting 对，文件大小约 9.10 MB。

索引重用策略：如果在目标路径上已经存在一个索引文件，且其更新时间晚于 `skills_data.json`，且 `schema` 版本不低于 3，则直接加载而不重新构建。传递 `--force` 可以跳过这一检查、强制重建。没有这个索引，后续的 `search`、`evaluate`、`compare-modes` 均无法执行。

4.3.2 evaluate

```
python ir_system/skills_ir_system.py evaluate --eval-set core_relevance.json
```

对单一检索模式（默认 `hybrid`）在指定评测集上执行离线评测。流程为：逐条读取 `ir_system/eval/core_relevance.json` 中的查询 (`query`) 和期望结果 (`expected_skill_names`)，调用引擎检索后，将排序结果与期望集合比对，计算五项指标——`Hit@K`、`Top1 Accuracy`、`MRR@K`、`Recall@K`、`Precision@K`——并对每条失败查询按原因分桶：`empty_results`（无返回结果）、`missed_expected`（期望结果未进 top-K）、`not_top1`（命中但不在首位）、`partial_expected`（多期望结果但未全部覆盖）。

结果同时持久化到 `ir_system/runtime/metrics_report.json`（完整指标明细）和 `ir_system/runtime/failure_buckets.json`（失败分桶详情）。两次报告的区别在于：`metrics_report` 给出系统的绝对分数（“这个模式跑得怎么样”），适合汇报；`failure_buckets` 按失败原因将查询归类，适合调试——发现哪类查询最容易漏召回、哪类查询排序位置偏低。

4.3.3 compare-modes

```
python ir_system/skills_ir_system.py compare-modes --eval-set core_relevance.json
```

这是消融实验的核心命令：在同一个评测集上，分别以 tfidf、bm25、hybrid 三种模式各跑一遍完整的评测流程，横向比较聚合指标（Hit@K、MRR@K、Recall@K、Precision@K），并标注每个评测集上哪种模式胜出。如果 `--eval-set` 传多个评测集（例如同时比较 `core_relevance.json` 和 `multilingual.json`），报告会按评测集拆开，方便观察不同语言分布下各模式的优劣变化。

与 `evaluate` 的区别在于：`evaluate` 只跑一种模式、看绝对分数；`compare-modes` 同时跑三种模式、看谁在什么条件下更优。对于回答“关掉 BM25 会怎样”“TF-IDF 单独用够不够”这类问题，这条命令直接给出量化答案。结果写入 `ir_system/runtime/comparison_report.json`，同时生成一份同名的 Markdown 文件供阅读。

4.3.4 search

```
python ir_system/skills_ir_system.py search "Qdrant_vector_search" --top-k 5
```

端到端查询命令。流程为：加载索引 → 对查询文本分词并扩展 → 计算混合得分（TF-IDF 余弦 + BM25 + 动态权重融合） → 施加后置 boost（标题匹配、token 覆盖率、热度修正等） → 按标准化标题去重（每个 skill name 只保留最高分的一条） → 返回 top-K 排序结果，终端打印 skill_name 和得分，同时将完整结果（含查询文本、模式、结果列表和索引摘要）写入 `ir_system/runtime/search_results.json`。

这条命令不涉及评测集和 Ground Truth——不计算 Precision/Recall，纯粹用于人工感知检索质量：搜一句话，看返回的前几条 skill 是否相关、排序是否合理。在调参阶段频繁使用，用于快速验证一个改动（例如调整 `alpha` 分段阈值或修改扩展词典）对排序的实际影响。

5 实验结果与对比分析

5.1 三种检索模式对比

表 3 汇总了 `core_relevance.json` 上的主要结果。Hit@5 三种模式都是 1.0，说明相关结果至少都能进前五；真正拉开差别的是排序位置和前五名里相关结果的占比。

表 3: 三种检索模式在 `core_relevance.json` 上的表现对比

模式	P@5	nDCG@5	MRR@5	Hit@5
TF-IDF	0.2762	0.8962	0.9107	1.0000
BM25	0.2714	0.8671	0.8996	1.0000
Hybrid	0.2810	0.8988	0.9087	1.0000

这个结果挺符合直觉。纯 TF-IDF 的 MRR@5 最高，说明在把最相关结果顶到第 1 位这件事上，向量空间模型还是主力。BM25 单独跑时不算差，但在这批数据上没有超过 TF-IDF。混合检索的作用更像“保守补分”：它没有把 MRR 再抬高，但把 P@5 和 nDCG@5 稍微往前推了一点，前五名整体更整齐。

5.2 BM25 权重扫描

为了看清楚 α 该压在什么区间，我把 BM25 权重固定后重新扫了一遍。结果没有单独放图，但结论很稳定： $\alpha = 0.02 \sim 0.05$ 一段最稳，继续加大 BM25 占比后， nDCG@5 和 MRR@5 会缓慢下滑，纯 BM25 的退化最明显。

这个扫描结果说明了两件事。第一，BM25 确实能帮一点忙，但只适合少量掺进去。第二，当前代码里那套“中文/短查询权重更低，长英文查询再稍微提高”的策略不是拍脑袋定的，它正好落在较稳的区间附近。

5.3 中文、英文与 mixed 查询差异

表 4 是 hybrid 模式按查询类型拆开的结果。英文查询的平均 α 为 0.0942，中文和 mixed 查询都压到 0.02。

表 4: Hybrid 模式按查询类型拆开的表现与平均 BM25 权重

查询类型	数量	平均 α	P@5	nDCG@5	MRR@5
English	24	0.0942	0.2750	0.9174	0.9410
Chinese	6	0.0200	0.2667	0.9385	0.9167
Mixed	12	0.0200	0.3000	0.8419	0.8403

这里最有意思的是中文查询。虽然它们的 BM25 权重最低， nDCG@5 反而不差。这和数据分布有关：文档主体几乎全英文，中文查询能命中，主要靠扩展词典把“前端”“结构化数据”“向量检索”映到对应英文术语上。这一步成功以后，TF-IDF 的向量相似度已经能把主相关结果推上来；BM25 再往上加，只会让零散中文 token 和局部词面匹配掺进更多噪声。

我又用 multilingual.json 做了交叉检查。那套评测里中文查询只有 4 条，纯 TF-IDF 和 hybrid 的 nDCG@5 都是 0.6577，BM25 则掉到 0.5886。这和式 (8) 的方向是一致的：中文部分先别让 BM25 说太多话。

5.4 失败案例

虽然三种模式的 Hit@5 都是 100%，但还有几个典型问题值得记一下。

- `copywriting for marketing`: 相关 skill 在前五里, 但 `marketing-skills-collection` 和 `marketing-automation` 这类泛化程度高的结果会抢到更前面, 说明领域词过宽时, 主题相关性和“任务是否对题”还没有完全拆开。
- `browser automation`: 相关结果有多个, `actionbook` 常常排不进更靠前的位置, 说明标题和描述里直说“`browser automation`”的 skill 更占便宜, 隐式相关项吃亏。
- `SEO audit`: `seo-audit` 往往能到第 1, 但另一个期望结果 `domain-authority-auditor` 不够靠前, 暴露出多相关文档场景下的覆盖问题。
- `SQL queries`: `supabase-postgres-best-practices`、`database-optimizer` 这类近邻文档有时会把 `sql-queries` 挤到第 3 或第 4, 说明“强相关概念邻居”对纯词法模型还是个老问题。

6 总结与展望

这套 IR 系统跑下来, 最大的感受是“简单模型不等于简单处理”。真正有用的不是单独的 TF-IDF 或 BM25, 而是整套围绕数据特征做的小修补: 字段加权、查询扩展、动态 α 、标题和热度 boost。当前数据上, TF-IDF 还是主骨架; BM25 更适合做轻量补分, 权重大了反而坏事。

局限也很清楚。第一, 文档侧英文占绝对多数, 中文检索基本靠手工扩展词典兜着。第二, 评测脚本里还没有原生 `nDCG`, 想看排序细节得另外补算。第三, 规则 boost 现在是手调常数, 还没有学到更细的排序偏好。后面如果继续做, 我会优先补三件事: 扩中文扩展词典、把 `nDCG` 正式纳入 CLI 评测、再加一层轻量 reranker, 把“概念相关但不是答案”的结果往后压一点。